



Estudiante:

Cedeño Pinto Scarlett Yamilett

Curso:

CDDEIA-ELNO-4-2

Asignatura:

Aprendizaje Automático

Docente:

Ing. Darwin Rodríguez Merchan

Tema:

Análisis Discriminante (LDA y QDA)

Índice

Índice	2
Comparación entre métricas de evaluación	¡Error! Marcador no definido.
Recall – Recuperacion o Tasa de Verdaderos Positivos	¡Error! Marcador no definido.
Ejemplo – Diagnostico de cáncer	¡Error! Marcador no definido.
F1 - Score.....	¡Error! Marcador no definido.
Ejemplo – Detectar SPAM	¡Error! Marcador no definido.
AUC - ROC	¡Error! Marcador no definido.
Ejemplo – Deteccion de fraude bancario.....	¡Error! Marcador no definido.
Conclusiones	7
Bibliografía	8

Introducción

El análisis discriminante es un método estadístico que busca encontrar una combinación de variables que permita caracterizar o separar dos o más clases de objetos o eventos, utilizada tanto como clasificador lineal como para reducir la dimensionalidad de los datos antes de clasificarlos, siendo una generalización del discriminante lineal de Fisher y estrechamente relacionada con el análisis de varianza ANOVA y el análisis de regresión, en el sentido de que todos estos métodos buscan expresar una variable como una combinación lineal de otras.

El objetivo central es asignar cada nueva observación a la clase más probable, a partir de modelar la distribución de los datos dentro de cada clase y aplicando la regla de Bayes para seleccionar la clase que maximiza la probabilidad posterior. Tanto LDA como QDA se derivan de modelos probabilísticos que modelan la distribución condicional de los datos para cada clase, y las predicciones se obtienen aplicando la regla de Bayes, seleccionando la clase que maximiza esta probabilidad posterior.

La clasificación tiene como objetivo predecir una variable de salida categórica o discreta, mientras que la regresión busca predecir una variable de salida numérica continua, aunque ambas son técnicas de aprendizaje supervisado que aprenden una relación entre variables predictoras y una variable objetivo a partir de datos etiquetados, la naturaleza de la variable objetivo es lo que determina si un problema debe abordarse como clasificación o como regresión (James, Witten, Hastie & Tibshirani, 2021).

Análisis Discriminante Lineal (LDA)

Es uno de los dos clasificadores clásicos derivados del análisis discriminante que asume que los valores de las variables predictoras siguen una distribución normal (gaussiana) dentro de cada clase y esto en términos formales significa que la distribución condicional de los datos dado la clase se modela como una distribución gaussiana multivariada. Junto con QDA, son atractivos porque cuentan con soluciones de forma cerrada que pueden calcularse fácilmente, son inherentemente multiclase, han demostrado funcionar bien en la práctica, y no requieren ajustar parámetros adicionales.

La diferencia principal entre LDA y QDA es que LDA asume que la matriz de covarianza es igual para todas las clases, mientras que QDA estima una matriz de covarianza distinta para cada clase. Entonces, bajo LDA, todas las clases tienen la misma "forma" y orientación de dispersión en el espacio de variables, y solo se diferencian por la ubicación de su media.

La función discriminante se construye a partir del logaritmo de la razón entre las probabilidades posteriores de dos clases. Para el caso binario, esto se reduce a observar el logaritmo del cociente entre la probabilidad de pertenecer a una clase y la otra, expresado en función de las probabilidades previas, las medias de cada clase y la matriz de covarianza común. El cálculo de esta función requiere estimar las probabilidades previas de cada clase, las medias de cada clase y las matrices de covarianza correspondientes.

Al compartir todas las clases la misma matriz de covarianza, la comparación entre los logaritmos de las probabilidades da como resultado una superficie de decisión lineal, ya que los términos cuadráticos de la matriz de covarianza se cancelan entre sí al ser idénticos para todas las clases, quedando únicamente una expresión lineal en función de la observación.

Se utiliza ampliamente en problemas de clasificación multiclase donde se sospecha que las clases tienen dispersiones similares, así como en tareas de reducción de dimensionalidad previas a la clasificación (Hastie, Tibshirani & Friedman, 2009).

Ventajas

Tiene una solución de forma cerrada fácil de calcular, es inherentemente multiclase, no requiere ajuste de hiperparámetros y funciona bien en la práctica. Además, puede utilizarse para realizar reducción de dimensionalidad supervisada, proyectando los datos hacia un subespacio de menor dimensión que maximiza la separación entre clases.

Limitaciones

Puede tener dificultades en escenarios de alta dimensionalidad debido a la inestabilidad en la estimación de la matriz de covarianza. Asimismo, cuando las clases realmente tienen estructuras de covarianza distintas entre sí, LDA subajusta los datos precisamente porque asume que todas las clases comparten una única matriz de covarianza, lo cual puede ser una simplificación excesiva de la realidad.

Análisis Discriminante Cuadrático (QDA)

Es el segundo de los dos clasificadores clásicos del análisis discriminante, caracterizado por generar una superficie de decisión cuadrática en lugar de lineal, mantiene el supuesto de que los datos de cada clase siguen una distribución gaussiana multivariada, pero a diferencia de LDA, cada clase puede tener su propia matriz de covarianza dentro de la densidad gaussiana que modela su distribución.

Aquí no existen restricciones sobre las matrices de covarianza de las gaussianas de cada clase, lo que en la práctica significa que el algoritmo estima una matriz de covarianza independiente para cada grupo, permitiendo que cada clase tenga su propia forma y orientación de dispersión. Al no existir ninguna restricción sobre las matrices de covarianza de cada clase, la comparación entre las densidades gaussianas de dos clases distintas produce superficies de decisión cuadráticas, ya que los términos cuadráticos de las matrices de covarianza ya no se cancelan entre sí como ocurre en LDA.

Este clasificador es preferible cuando el proceso generador de los datos realmente produce una matriz de covarianza distinta para cada clase; y forzar el supuesto de covarianza compartida de LDA produciría una frontera de decisión menos precisa. QDA resulta entonces más adecuado en conjuntos de datos con suficientes observaciones por clase como para estimar de forma confiable cada matriz de covarianza individual.

Ventajas

Cuando existe una diferencia real entre las matrices de covarianza de las clases, QDA logra ajustar dos (o más) matrices de covarianza y produce una frontera de decisión no lineal, mientras que LDA subajusta los datos al asumir una única matriz de covarianza compartida. Esto hace que QDA sea más flexible ante escenarios donde las clases realmente difieren en su dispersión.

Limitaciones

Al estimar una matriz de covarianza separada por cada clase, QDA requiere estimar una cantidad considerablemente mayor de parámetros que LDA, esto agrava el mismo problema de inestabilidad en la estimación de la covarianza que afecta a LDA en escenarios

de alta dimensionalidad o con pocas muestras por clase (Hastie et al., 2009), aumentando el riesgo de sobreajuste cuando el número de observaciones disponibles es limitado.

Conclusiones

LDA se comporta como un clasificador estable y computacionalmente eficiente gracias a su solución de forma cerrada y a la ausencia de hiperparámetros que ajustar, lo cual fue consistente con los resultados obtenidos sobre el dataset Wine, donde alcanzó un desempeño alto y estable pese al tamaño moderado de la muestra (178 observaciones), el desempeño similar entre ambos modelos sobre el dataset Wine sugiere que el supuesto de covarianza compartida entre clases, propio de LDA, no resultó demasiado restrictivo para este conjunto de datos en particular, lo que respalda la idea de que LDA no subajustó de forma significativa.

QDA demostró mayor flexibilidad al estimar una matriz de covarianza independiente por cada clase, lo que le permitió adaptarse a posibles diferencias en la dispersión de los tres cultivares del dataset Wine, logrando un desempeño competitivo frente a LDA en las métricas evaluadas,

En comparación, las métricas de accuracy, precisión, recall y F1-Score obtenidas para LDA y QDA fueron cercanas entre sí, y las fronteras de decisión visualizadas en dos dimensiones confirmaron la diferencia teórica esperada (lineal para LDA, cuadrática para QDA), aunque sin una ventaja dramática de un modelo sobre el otro en este caso particular.

En escenarios con muestras reducidas o cuando se prioriza la interpretabilidad y la simplicidad computacional, LDA resulta la opción más adecuada; en cambio, QDA es preferible cuando existe evidencia clara de que las clases tienen estructuras de covarianza distintas y se dispone de suficientes datos para estimarlas de forma confiable, como podría

ocurrir en conjuntos de datos más grandes o con mayor separación natural entre grupos.

Bibliografía

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2a ed.). Springer.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning with applications in R* (2a ed.). Springer. <https://www.statlearning.com/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

scikit-learn developers. (s.f.). Linear and quadratic discriminant analysis. Scikit-learn 1.9.0 documentation. Recuperado el 9 de julio de 2026 de https://scikit-learn.org/stable/modules/lda_qda.html

Wikipedia contributors. (2026). Linear discriminant analysis. En Wikipedia, La enciclopedia libre. Recuperado el 9 de julio de 2026 de https://en.wikipedia.org/wiki/Linear_discriminant_analysis