

Estudiante:

Cedeño Pinto Scarlett Yamilett

Facultad:

Ciencias Matemáticas y Físicas

Curso:

CDDEIA-ELNO-4-2

Asignatura:

Aprendizaje Automático

Docente:

Ing. Darwin Rodríguez Merchan

Tema:

Fundamentos de regresión y regularización

Índice

Índice	2
Comparación entre métricas de evaluación	3
Recall – Recuperacion o Tasa de Verdaderos Positivos	3
Ejemplo – Diagnostico de cáncer	4
F1 - Score.....	4
Ejemplo – Detectar SPAM	5
AUC - ROC	5
Ejemplo – Deteccion de fraude bancario.....	6
Conclusiones	7
Bibliografía	8

Comparación entre métricas de evaluación

Una vez entrenado un algoritmo de clasificación dentro del Aprendizaje Supervisado, hay que evaluarlo para determinar si generaliza bien o presenta overfitting, y las métricas que se prioricen para esa evaluación dependerán de los costos, beneficios y riesgos del problema específico, pues en un caso como la clasificación de spam por ejemplo, puede tener más sentido priorizar el Recall para capturar todos los correos no deseados.

Recall – Recuperacion o Tasa de Verdaderos Positivos

También conocido como sensibilidad o tasa positiva verdadera, es una métrica que mide la capacidad de un modelo para identificar correctamente todas las instancias relevantes, indicando qué proporción de los positivos reales fueron detectados correctamente por el modelo, siendo la más utilizada dentro de las tareas de clasificación en Aprendizaje Supervisado.

Su cálculo se basa en la fórmula $\text{Recall} = \text{True Positives} / (\text{True Positives} + \text{False Negatives})$, donde los verdaderos positivos representan los casos positivos correctamente identificados y los falsos negativos son los casos positivos que el modelo no logró detectar, esta relación matemática determina qué tan efectivo es el modelo para no dejar pasar instancias relevantes.

Es importante en contextos donde los falsos negativos tienen consecuencias críticas, ya que omitir un caso positivo real puede ser más costoso que generar una alarma falsa, aunque presenta la desventaja de que puede inflarse artificialmente si el modelo predice todos los casos como positivos, lo que obliga a considerarla siempre con otras métricas como la Precisión o el F1-Score.

Ejemplo – Diagnostico de cáncer

Supongamos que un modelo analiza 100 pacientes, de los cuales 40 tienen cáncer real y 60 no lo tienen y el modelo identifica correctamente 32 pacientes con cáncer (verdaderos positivos), pero no detecta a 8 pacientes que sí tenían cáncer (falsos negativos). Aplicamos la fórmula: **Recall** = $32 / (32 + 8) = 32 / 40 = 0.80 \rightarrow 80\%$

Esto significa que el modelo detectó correctamente el 80% de los casos reales de cáncer, dejando al 20% restante, en un contexto médico representa un riesgo crítico, ya que esos 8 pacientes no diagnosticados no reciben tratamiento a tiempo, razón por la que en este tipo de problemas se prefiere un modelo que detecte la mayor cantidad posible de casos positivos reales aunque a veces se equivoque con pacientes sanos.

F1 - Score

Es la media de la Precisión y el Recall, combina ambas en una única cifra que equilibra su importancia, es preferible cuando se trabaja con conjuntos de datos con clases desequilibradas, ya que ofrece una visión más equilibrada de la capacidad del modelo para identificar instancias relevantes correctamente mientras minimiza los errores.

Su escala va de 0 a 1, donde 1 indica una precisión y recuperación perfecta y 0 es deficiente, además cuando la Precisión y el Recall tienen valores similares, el F1-Score también será similar a esos valores, pero cuando ambas métricas están muy separadas, el F1-Score tenderá a acercarse al valor de la que sea peor, penalizando así a los modelos que funcionan bien en una métrica pero no en la otra.

Al penalizar los valores extremos asegura que solo se obtenga una puntuación alta cuando tanto la Precisión como el Recall son razonablemente elevados, lo que lo convierte en una métrica esencial en campos como el diagnóstico médico o la recuperación de información, aunque presenta la limitación de que puede no ser adecuado para todos los casos de uso, especialmente cuando los costos de los falsos positivos y los falsos negativos son muy distintos entre sí.

.

Ejemplo – Detectar SPAM

Un modelo analiza 100 correos, de los cuales 50 son spam y 50 son legítimos, clasifica correctamente 40 como spam (verdaderos positivos), deja 10 spam sin detectar (falsos negativos) y marca incorrectamente 5 correos legítimos como spam (falsos positivos). Aplicando las fórmulas:

$$\text{Precisión} = 40 / (40 + 5) = 40 / 45 = 0.89 \rightarrow 89\%$$

$$\text{Recall} = 40 / (40 + 10) = 40 / 50 = 0.80 \rightarrow 80\%$$

$$\text{F1-Score} = 2 \times (0.89 \times 0.80) / (0.89 + 0.80) = 2 \times 0.712 / 1.69 = 0.843 \rightarrow 84\%$$

El F1-Score de 84% refleja un equilibrio real entre ambas métricas, y como la Precisión y el Recall no están muy separadas, el resultado es cercano a ambas, lo que confirma que el modelo tiene un rendimiento consistente sin sacrificar una métrica por la otra.

AUC - ROC

ROC (Receiver Operating Characteristic) es un gráfico utilizado para evaluar modelos de clasificación que representa la Tasa de Verdaderos Positivos (Recall) contra la Tasa de Falsos Positivos, con la particularidad de que el umbral por el que se clasifica un elemento como 0 o 1 se va modificando progresivamente para generar todos los puntos de la gráfica, donde los más cercanos a la coordenada (0,1) representan los umbrales con mejor rendimiento para el modelo.

A partir de esa curva se obtiene el AUC (Area Under Curve), útil para problemas de clasificación binaria cuyo valor se encuentra entre 0 y 1, donde 0 equivale es aleatorio y 1 indica generaliza de manera óptima, siendo valiosa para comparar el rendimiento de dos modelos diferentes siempre que el conjunto de datos esté casi equilibrado y permitiendo además ajustar el umbral de decisión según los costos del problema, priorizando una FPR más baja cuando los falsos positivos son costosos o una TPR más alta cuando los falsos negativos son los más críticos.

Perseguir un AUC cada vez más alto provoca sobreajuste del modelo, ya que agregar predictor tras predictor en busca de décimas adicionales puede degradar la generalización y la utilidad práctica, por lo que la Ley de Goodhart dice que cuando una medida se convierte en un objetivo, deja de ser una buena medida, y se debe complementar su uso con validación cruzada para probar el modelo con datos nunca antes vistos.

Ejemplo – Deteccion de fraude bancario

Tenemos dos modelos que detectan transacciones fraudulentas y queremos comparar cuál es mejor usando AUC-ROC. Al variar el umbral de decisión en cada modelo se obtienen distintas combinaciones de TPR y FPR, y al calcular el área bajo cada curva se obtiene:

Modelo A: AUC = 0.91

Modelo B: AUC = 0.74

Esto significa que el Modelo A tiene un 91% de probabilidad de distinguir correctamente una transacción fraudulenta de una legítima y el Modelo B solo lo logra el 74% de las veces, por lo que Modelo A es claramente superior, pero si el banco considera que los falsos positivos (bloquear una tarjeta legítima) es muy costoso en experiencia al cliente,

se elegiría un umbral que mantenga la FPR baja aunque se reduzca algo la TPR, mientras que si el mayor riesgo es dejar pasar fraudes reales, se priorizaría un umbral que maximice la TPR aunque aumente ligeramente la FPR.

Conclusiones

Al comparar GridSearchCV y RandomizedSearchCV, ambos llegaron a resultados muy similares en términos de Recall, pero GridSearchCV evaluó las 10 combinaciones posibles del param_grid de forma exhaustiva, lo que garantiza encontrar la mejor combinación dentro del espacio definido, mientras que RandomizedSearchCV evaluó solo 6 combinaciones, siendo más rápido sin sacrificar la calidad del resultado, demostrando que cuando el espacio de hiperparámetros es pequeño como en este caso ambos métodos son igualmente válidos, pero en problemas reales con decenas de parámetros y miles de combinaciones posibles, RandomizedSearchCV es más eficiente porque permite explorar un espacio mucho mayor en menos tiempo, la elección entre uno y otro depende del tamaño del problema y los recursos computacionales disponibles.

El ajuste del umbral de decisión demostró ser una herramienta para controlar el comportamiento del modelo según las necesidades del problema, ya que al reducir el umbral de 0.5 a 0.3 el modelo se volvió más permisivo y el Recall aumentó porque clasifica más casos como positivos reduciendo los falsos negativos, aunque esto también mete más falsos positivos lo que penaliza el F1-Score, mientras que al subir el umbral a 0.7 ocurre lo contrario, el modelo se vuelve más estricto, reduce los falsos positivos y mejora la Precisión pero sacrifica el Recall dejando fuera casos positivos reales, confirmando que el umbral por defecto de 0.5 no siempre es el más adecuado y debe ajustarse según los costos asociados a cada tipo de error.

No existe una métrica universalmente correcta para evaluar un modelo de clasificación, el Recall es la métrica más crítica cuando los falsos negativos son costosos

como en el diagnóstico médico, el F1-Score es más adecuado cuando se necesita un equilibrio entre detectar correctamente los positivos y no generar demasiadas alarmas falsas como en la detección de spam, y el AUC-ROC es útil para comparar modelos de forma general sin depender de un umbral fijo, por lo que la validación cruzada complementa el análisis asegurando que el modelo generalice bien a datos nunca antes vistos y no solo memorice los patrones del conjunto de entrenamiento.

Bibliografía

Chugh, V. (2025, 12 de noviembre). Puntuación F1 en machine learning: Una métrica equilibrada para la precisión y la recuperación. DataCamp.
<https://www.datacamp.com/es/tutorial/f1-score>

Coralogix. (2023, 20 de agosto). Recall: A key metric for evaluating model performance.
<https://coralogix.com/ai-blog/recall-a-key-metric-for-evaluating-model-performance/>

Díaz, R. (2020, 8 de mayo). Métricas de clasificación. The Machine Learners.
<https://www.themachinelearners.com/metricas-de-clasificacion/>

Goldstein-Greenwood, J. (2022, 15 de abril). ROC curves and AUC for models used for binary classification. University of Virginia Library.
<https://library.virginia.edu/data/articles/roc-curves-and-auc-for-models-used-for-binary-classification>

Google for Developers. (2026, 5 de febrero). Clasificación: Exactitud, recuperación, precisión y métricas relacionadas. <https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=es-419>

Google for Developers. (2025, 1 de octubre). Clasificación: ROC y AUC.
<https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc?hl=es-419>

Keylabs. (2024, 25 de octubre). Understanding the F1 score and AUC-ROC curve.
<https://keylabs.ai/blog/understanding-the-f1-score-and-auc-roc-curve/>

Ultralytics. (2026, 29 de enero). ¿Qué es la puntuación F1? Definición, fórmula y casos de uso. <https://www.ultralytics.com/es/glossary/f1-score>

Firma de estudiante:	Cedeño Scarlett CI: 0943793273
-----------------------------	-----------------------------------